Bài 1

$$x_t = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad h_{t-1} = \begin{bmatrix} 0.5 \\ 0.2 \end{bmatrix} \quad b_h = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$W_{xh} = \begin{bmatrix} 0.5 & 0.2 \\ 0.1 & 0.4 \end{bmatrix} \quad W_{hh} = \begin{bmatrix} 0.3 & 0.1 \\ 0.2 & 0.5 \end{bmatrix}$$

$$a_t = W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1} + b_h$$

$$a_t = \begin{bmatrix} 0.5 \\ 0.1 \end{bmatrix} + \begin{bmatrix} 0.17 \\ 0.2 \end{bmatrix} = \begin{bmatrix} 0.67 \\ 0.3 \end{bmatrix}$$

$$\tanh(a_t) = h_t = \tanh \begin{bmatrix} 0.67 \\ 0.3 \end{bmatrix} = \begin{bmatrix} \tanh 0.67 \\ \tanh 0.3 \end{bmatrix} = \begin{bmatrix} 0.585 \\ 0.291 \end{bmatrix}$$

Bài 2.

I	did	not	like	this	movie
x_1	x_2	x_3	x_4	x_5	x_6

No

$h_1 = f(x_1, h_0)$

$h_2 = f(x_2, h_1)$

$\vdots$

$h_6 = f(x_6, h_5)$

Tại thời điểm đó model đọc "like"

$h_4 = f(x_4, h_3)$

$h_4 = f(x_4, f(x_3, h_2))$

do đó từ "not" (x_3) có ảnh hưởng tới hidden state khi đọc ~~từ~~ like

KLONG

Bài 3

- S_1: "dog bites man"
- S_2: "man bites dog"

- Average Word2Vec ⇒ thì phân biệt 2 câu này vì khi tính TB ~~[illegible]~~ thì thứ 2 câu S_1, S_2 có vector giống nhau.

- RNN có khả năng phân biệt thứ tự dựa trên tính toán tự cơ mô hình

ở S1 thì x_1 dog có ảnh hưởng tới h_2, h_3
dẫn tới S_1, S_2 sẽ được RNN biểu diễn khác nhau.

Bài 4 - LSTM cell

forget gate = 0.9
input gate = 0.2
candidate = 0.5
cell state prev = 0.8

$$c_t = f_t \cdot c_{t-1} + i_t \tilde{c}_t$$

$$c_t = 0.9 \cdot 0.8 + 0.2 \cdot 0.5$$
$$= 0.72 + 0.1 = 0.82.$$

Bài 5 - Vanishing gradient

- Gradient : $\frac{\partial h_T}{\partial h_t} = \prod_{k=t+1}^{T} \frac{\partial h_k}{\partial k_{k-1}}$

Nếu gradient gần nhiều time step nhỏ hơn 1 khi đó có thể vì dụ $0.5^{50} \approx 8.88 \times 10^{-16}$ vì thì hiện gradient yếu (gần 0) đây là Vanishing gradient.

Còn nếu gradient gần có nhiều step nhỏ lớn hơn 1 khi đó $1.5^{50} \approx 6.38 \cdot 10^{8}$ dẫn tới exploding gradient.

Chuỗi càng dài, thế càng nhiều phần tử và càng khó để có gradient ổn định → khó học.

KLONG